MNIST VERİ SETİ İLE

MLP TABANLI EL YAZISI RAKAM TANIMA

Deney Raporu

Öğrenci numarası	22120205392
Öğrenci ismi ve soyismi	Serchat Chasan
Kullanılan kütüphane	PyTorch
Model türü	Multi-Layer Perceptron (MLP)
Veri seti	MNIST

28 Ekim 2026

1. Giriş

Bu çalışmanın amacı, MNIST veri seti kullanılarak Multi-Layer Perceptron (MLP) tabanlı bir el yazısı rakam tanıma modeli geliştirmek ve farklı model mimarilerinin performanslarını karşılaştırmaktır. MNIST veri seti, 0 ile 9 arasındaki el yazısı rakamları içeren, 28 × 28 piksel boyutlarında gri tonlamalı görüntülerden oluşmaktadır.

Çalışmada PyTorch kullanılarak iki farklı MLP modeli oluşturulmuş, modeller sıfırdan eğitilmiş ve performansları eğitim, doğrulama ve test ölçütleri üzerinden değerlendirilmiştir. Ek olarak, kendi el yazımla yazdığım öğrenci numarasını modele vererek kişisel bir görüntü üzerindeki tanıma performansı incelenmiştir.

2. Kullanılan Yöntemler

2.1. Veri Seti ve Ön İşleme

Çalışmada MNIST veri seti kullanılmıştır. Her görüntü 28 × 28 piksel boyutundadır. Görüntüler, MLP modeline girdi olarak verilebilmesi için 784 elemanlı vektörlere dönüştürülmüştür. Piksel değerlerine normalizasyon uygulanmıştır.

MNIST veri kümesindeki 60.000 eğitim görüntüsü, sabit tohum değeri 42 kullanılarak 50.000 eğitim ve 10.000 doğrulama görüntüsüne ayrılmıştır. Ayrıca 10.000 görüntüden oluşan ayrı test kümesi kullanılmıştır. Bu ayrım, modelin eğitim sırasında görmediği veriler üzerindeki performansını değerlendirmeyi sağlamıştır.

2.2. Model Mimarileri

İki gizli katmana sahip iki MLP mimarisi karşılaştırılmıştır:

- Model 1 — MLP 256-128: 784 giriş birimi, 256 nöronlu birinci gizli katman, 128 nöronlu ikinci gizli katman ve 10 çıkış birimi.
- Model 2 — MLP 128-64: 784 giriş birimi, 128 nöronlu birinci gizli katman, 64 nöronlu ikinci gizli katman ve 10 çıkış birimi.

Her iki modelde gizli katmanlarda ReLU aktivasyon fonksiyonu kullanılmıştır. Çıkış katmanı, 0–9 arasındaki on rakam sınıfını temsil etmektedir. Modeller CNN kullanmadan, MLP mimarisiyle sıfırdan eğitilmiştir.

2.3. Eğitim Parametreleri

Parametre	Değer
Epoch sayısı	10
Batch size	128
Öğrenme oranı	0.001
Optimizer	Adam
Kayıp fonksiyonu	CrossEntropyLoss
Aktivasyon fonksiyonu	ReLU
Gizli katman sayısı	2
Çalıştırma cihazı	CPU

3. Deneysel Sonuçlar

3.1. Model Performansları

Eğitim tamamlandıktan sonra elde edilen sonuçlar aşağıdaki tabloda karşılaştırılmıştır.

Ölçüt	Model 1: 256-128	Model 2: 128-64
Parametre sayısı	235.146	109.386
Eğitim süresi	96,48 sn	86,91 sn
Son Training Loss	0,0154	0,0327
Son Validation Loss	0,0988	0,0968
Son Training Accuracy	%99,55	%99,00
Son Validation Accuracy	%97,52	%97,23
Test Loss	0,0791	0,0821
Test Accuracy	%97,85	%97,66

3.2. Loss Grafiklerinin Değerlendirilmesi

Eğitim grafikleri incelendiğinde her iki modelin training loss değerinin epoch sayısı arttıkça azaldığı görülmektedir. Bu durum modellerin eğitim verisindeki örüntüleri öğrendiğini gösterir. Validation loss değerleri de genel olarak azalmıştır; ancak eğitim kaybı azalmaya devam ederken doğrulama kaybındaki iyileşmenin yavaşlaması, bir miktar aşırı öğrenme (overfitting) belirtisi olabileceğini düşündürmektedir.

Son çalıştırmada Model 1'in training loss değeri 0,0154, validation loss değeri 0,0988 olarak ölçülmüştür. Model 2'nin ilgili değerleri 0,0327 ve 0,0968'dir.

3.3. Accuracy Grafiklerinin Değerlendirilmesi

Her iki modelde de epoch sayısı arttıkça doğruluk genel olarak yükselmiştir. Son epoch sonunda Model 1'in training accuracy değeri %99,55, validation accuracy değeri %97,52'dir. Model 2'de bu değerler sırasıyla %99,00 ve %97,23'tür. Eğitim doğruluğunun doğrulama doğruluğundan yüksek olması, modellerin eğitim verisinde daha başarılı olduğunu; aradaki fark ise bir miktar aşırı öğrenme olasılığını düşündürmektedir.

4. Model Karşılaştırması ve Analiz

Son çalıştırmada Model 1, %97,85 test doğruluğuyla Model 2'nin %97,66 sonucundan 0,19 yüzde puan daha yüksek performans göstermiştir.

Model 1'in parametre sayısı 235.146, Model 2'nin parametre sayısı 109.386'dır. Model 2 yaklaşık %53,5 daha az parametre kullanmıştır. Son çalıştırmada eğitim süresi Model 1 için 96,48 saniye, Model 2 için 86,91 saniyedir; Model 2 yaklaşık 9,57 saniye daha kısa sürede eğitilmiştir. Süreler donanım ve çalışma koşullarına göre değişebilir.

Sonuçlar, daha büyük Model 1'in test doğruluğunda küçük bir avantaj sağladığını; daha küçük Model 2'nin ise yaklaşık %53,5 daha az parametre ve daha kısa eğitim süresiyle benzer bir performans sunduğunu göstermektedir.

5. Kendi El Yazımla Öğrenci Numarasının Tanınması

MNIST veri setindeki örneklerden farklı olarak, kendi el yazımla oluşturduğum öğrenci numarasının görüntüsünü modele girdi olarak verdim. Öğrenci numaram 22120205392 şeklindedir.

Görüntü işleme aşamasında fotoğraf yüklendi, numaranın bulunduğu bölge kırpıldı ve rakamlar ayrı görüntüler hâline getirildi. Ardından görüntüler gri tonlamaya dönüştürüldü, 28 × 28 piksel boyutuna ayarlandı ve normalizasyon uygulandı.

2 – 2 – 1 – 2 – 0 – 2 – 0 – 5 – 3 – 9 – 2

Modelin tahmin ettiği rakam dizisi 22120205392 olarak elde edilmiş ve öğrenci numarasıyla eşleşmiştir. Kod çıktısında 11 rakam bulunduğu raporlanmıştır. Bu sonuç, eğitilmiş MLP modelinin bu kişisel el yazısı örneğinde doğru tahmin üretebildiğini göstermektedir. Bununla birlikte, tek bir örneğin doğru tanınması modelin tüm el yazıları üzerinde aynı başarıyı göstereceğini kanıtlamaz.

6. Tartışma ve Sınırlılıklar

Deney, MLP mimarisinin el yazısı rakam tanıma görevinde başarılı sonuçlar verebildiğini göstermiştir. İki modelin karşılaştırılması, gizli katmanlardaki nöron sayısının parametre sayısını, eğitim süresini ve tahmin performansını etkilediğini ortaya koymuştur.

Çalışmanın sınırlılıklarından biri, modellerin yalnızca 10 epoch boyunca eğitilmesi ve iki mimarinin karşılaştırılmasıdır. Farklı öğrenme oranları, batch size değerleri ve katman yapılandırmaları denenerek daha kapsamlı bir analiz yapılabilir. Kişisel el yazısı deneyi de tek bir numara görüntüsüyle sınırlıdır; farklı yazı stilleri, kalem kalınlıkları, görüntü açıları ve ışık koşullarıyla ek testler yapılması gerekir.

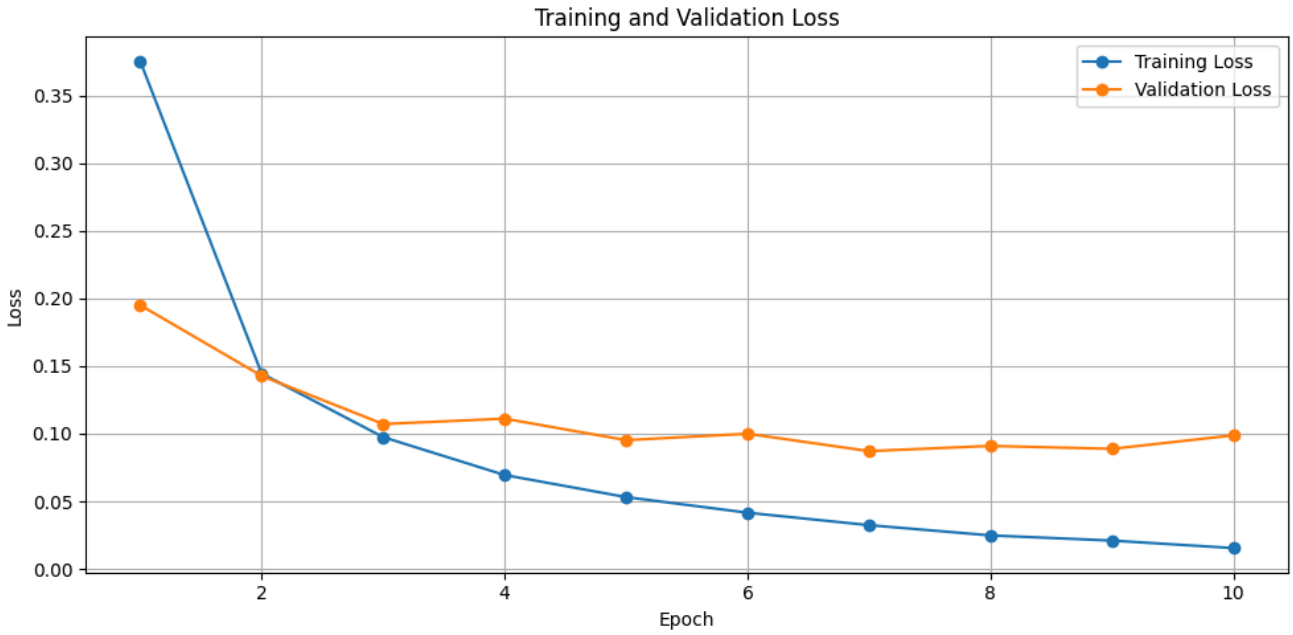
7. Sonuç

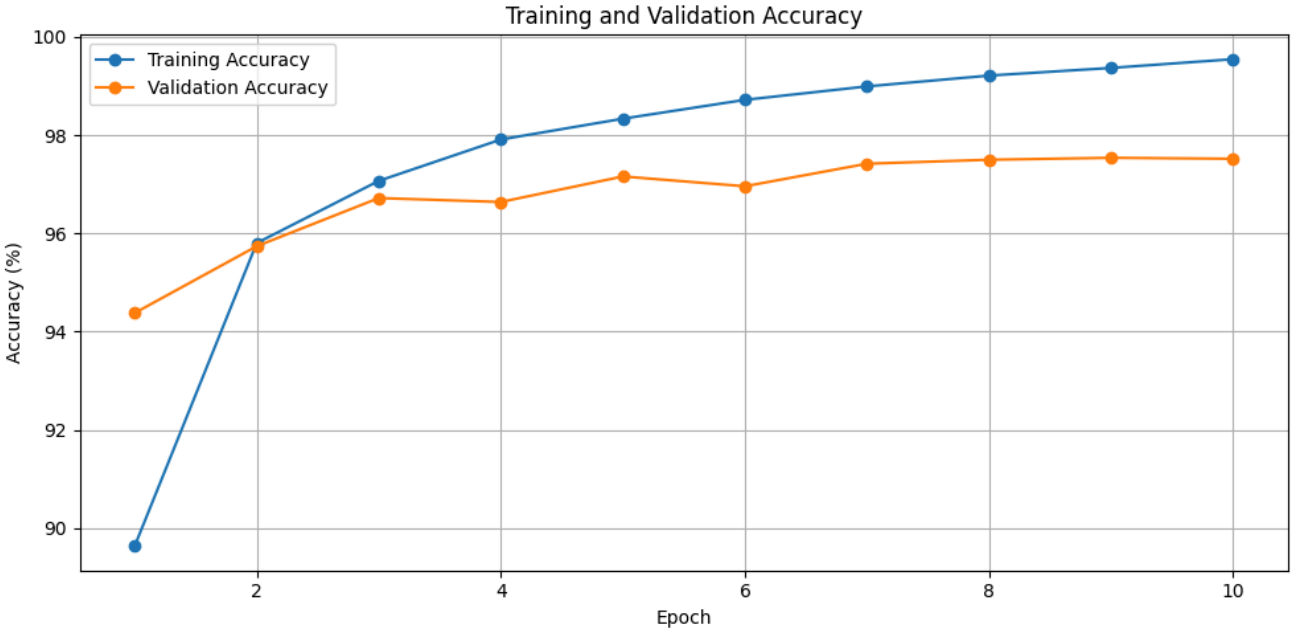
Bu çalışmada MNIST veri seti kullanılarak iki farklı MLP modeli geliştirilmiş ve sıfırdan eğitilmiştir. Modellerin eğitim ve doğrulama süreçleri loss ve accuracy ölçütleriyle incelenmiş, test performansları karşılaştırılmıştır. Son çalıştırmada Model 1 %97,85, Model 2 ise %97,66 test doğruluğuna ulaşmıştır.

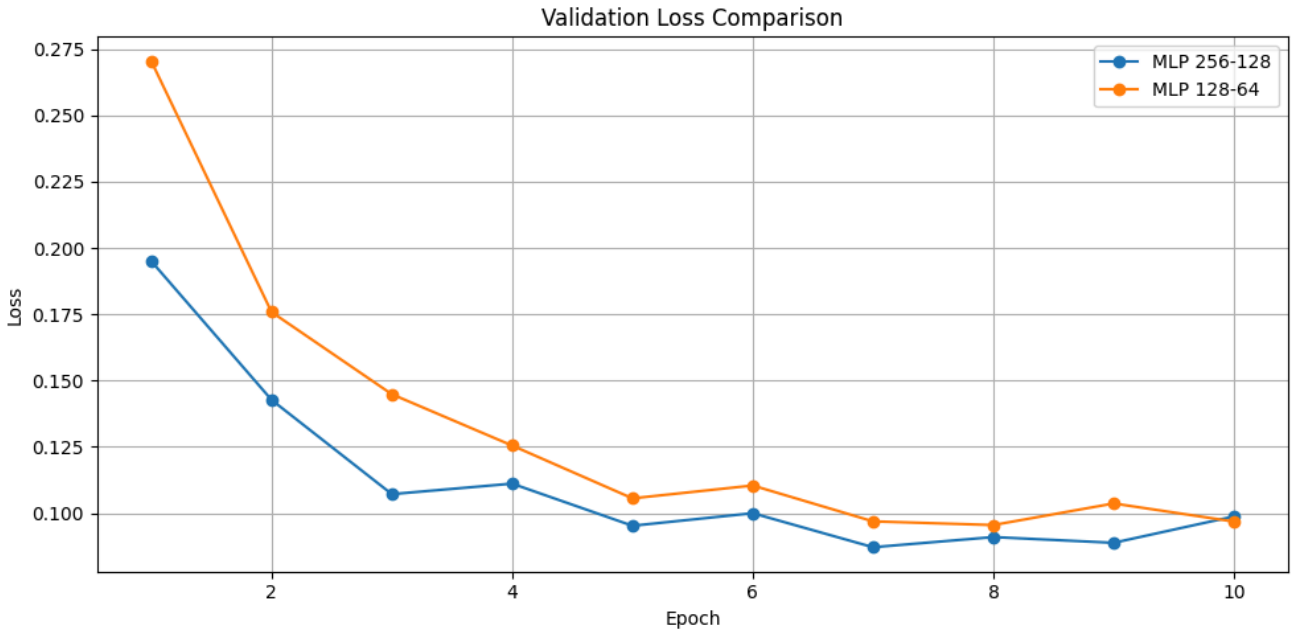
Model 1, %97,85 ile daha yüksek test doğruluğu sağlamıştır. Model 2 ise daha az parametre ve daha kısa eğitim süresiyle benzer performans göstermiştir. Kendi el yazımla yazdığım 22120205392 numarasının doğru tanınması, MLP modelinin bu kişisel el yazısı görüntüsünde başarılı tahmin üretebildiğini göstermiştir.

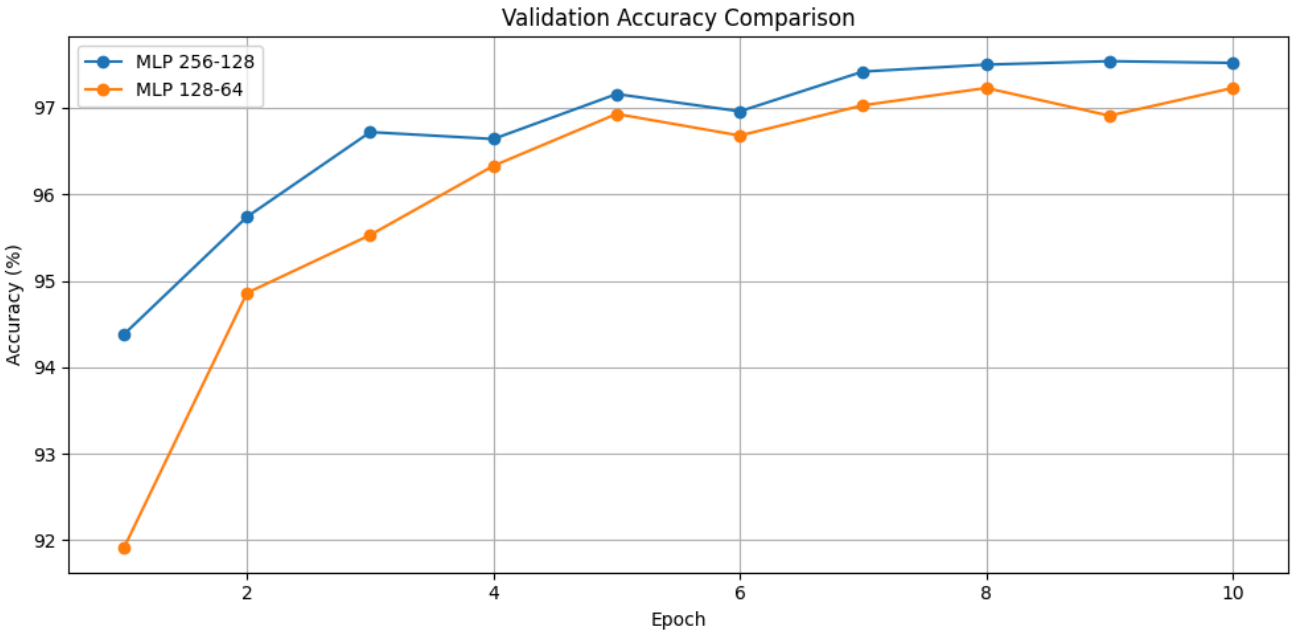
Sonuç olarak bu çalışma; MLP mimarisi oluşturma, model eğitimi, veri kümelerini ayırma, performans ölçütlerini yorumlama ve farklı model yapılandırmalarını karşılaştırma konularında uygulamalı deneyim sağlamıştır.

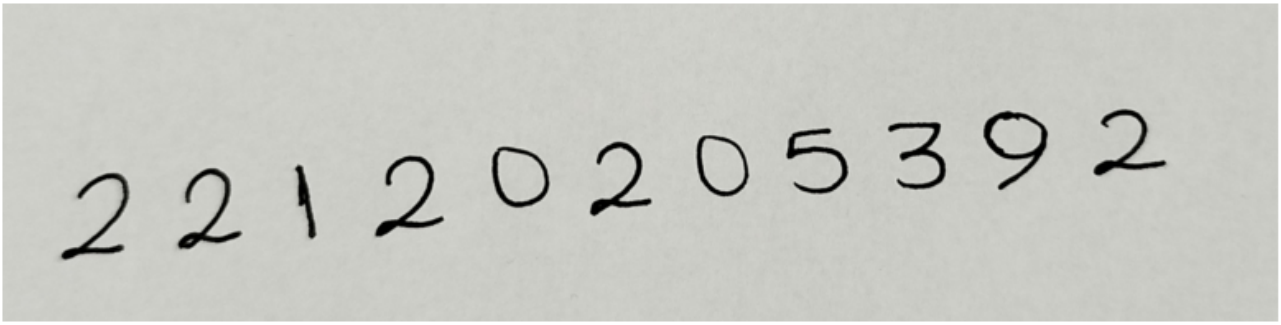
Notebook Çıktıları






Validation Loss Comparison
MLP 256-128
MLP 128-64
Loss
Epoch
0.275
0.250
0.225
0.200
0.175
0.150
0.125
0.100
2
4
6
8
10


Validation Accuracy Comparison
MLP 256-128
MLP 128-64
Accuracy (%)
Epoch
97
96
95
94
93
92
2
4
6
8
10


2212020539 2


2 2 1 2 0 2 0 5 3 9 2